

# **Um Modelo de Aprendizado de Agentes Inteligentes Baseado em Técnicas de Data Mining**

**Leandro Maciel, Thereza Patrícia P. Padilha**

Curso de Sistemas de Informação – Centro Universitário Luterano de Palmas (CEULP)  
Palmas, TO, Brasil

leandro@ulbra-to.br, thereza@ulbra-to.br

**Resumo:** *Os agentes inteligentes possuem a capacidade de perceber alterações no ambiente e realizar as tarefas em busca do seu objetivo. Este artigo descreve um modelo alternativo de aprendizagem de agentes inteligentes a partir da utilização de técnicas de data mining. Neste caso, os agentes adquirem conhecimento através de uma base de dados e tomam decisões com o acúmulo de experiência. Essa experiência é adquirida com a análise contínua na base de dados. O processo de aprendizagem deste agente inicia com a coleta de informações que atendem às especificações de projeto, analisa o conhecimento e, por fim, age no ambiente. Para este modelo, serão apresentados o processo de percepção, a forma de aprendizagem baseada no cálculo da entropia e o estágio atual do desenvolvimento.*

## 1 Introdução

Nos últimos anos, várias pesquisas sobre agentes inteligentes têm sido realizadas, sendo objetos de estudos não somente na área da Computação, mas também na Psicologia, Sociologia e Filosofia. A maioria dos estudos concentra-se na área de Inteligência Artificial (IA), mais precisamente na Inteligência Artificial Distribuída (IAD), na qual foram realizados estudos pioneiros sobre o comportamento de agentes inteligentes [Bordini et al. 2001]. Os agentes inteligentes possuem uma capacidade de coletar, filtrar, processar e produzir informações, tendo como suporte uma base de conhecimento [Russell & Norvig 1995].

Em geral, um agente inteligente usa seu conhecimento para reconhecer os planos do usuário, com o objetivo de encontrar oportunidades para auxiliá-lo. Segundo Wood, um agente inteligente é uma entidade cognitiva, ativa e autônoma, ou seja, possui um sistema interno de tomada de decisões [Wood 1994]. Agindo sobre o ambiente e sobre os outros agentes que o rodeiam, um agente não necessita de algo ou de alguém para o guiar, pois possui mecanismos próprios de percepção do ambiente. Desse modo, um agente é uma entidade ativa que atua sempre a favor do usuário, possui um conhecimento sobre determinado domínio e é capaz de perceber situações em que deve se ativar baseado nos dispositivos de raciocínio.

O aprendizado de um agente inteligente é considerado um processo constante e complexo pois, necessita em coletar um extensivo conhecimento de um determinado domínio. Este trabalho apresenta um modelo de aprendizagem alternativo para agentes inteligentes, que consiste em realizar a extração de conhecimento a partir da base de dados, utilizando técnicas de *data mining* (mineração de dados). Com isso, o agente é capaz de adquirir conhecimento para tomar decisões em busca de seu objetivo.

*Data mining* é um dos passos do processo de extração de dados, permitindo ao usuário explorar e inferir informações úteis a partir dos dados extraídos, pois revela os relacionamentos que estão encapsulados. Para a exploração dos dados existem inúmeras técnicas, tais como: redes neurais, indução de regras e indução de árvores de decisão.

O presente artigo está organizado da seguinte forma: na seção 2 é descrita uma visão geral sobre agentes inteligentes; na seção 3 são apresentadas as etapas do processo de extração de conhecimento de dados; na seção 4 é exemplificado o cálculo da entropia dos atributos de uma certa base de dados; na seção 5 é apresentada uma descrição da implementação do modelo proposto; e na seção 6 são apresentadas as considerações finais deste trabalho.

## 2 Aprendizado de Agentes Inteligentes

O termo **agente** tem sido bastante utilizado por diversos pesquisadores que trabalham tanto na área de Inteligência Artificial quanto na de Ciência da Computação como um todo. Diante disso, existe uma considerável discussão para a definição desse termo. Um agente pode ser definido como um sistema de computador que está *situado* em algum *ambiente*, sendo capaz de realizar *ações autônomas* neste ambiente a fim de atingir seus objetivos

[Wooldridge 1999]. Esta definição possui dois pontos a serem esclarecidos: primeiro, a definição refere-se a “agentes” e não a “agentes inteligentes”; segundo, não foi mencionado qual o tipo do ambiente que o agente ocupa. Sendo assim, a definição possui uma maior abrangência, pois não se encontra agentes somente na área da informática. Existem agentes na área da Educação, porém esse tipo de agente é representado por um ser humano, que toma decisões a partir de suas experiências ou através da análise de uma determinada informação.

A definição do termo **agentes inteligentes** é, de certa forma, mais complicada, porque, até hoje, não existe uma definição consagrada de inteligência. A inteligência de um agente pode ser adquirida através da análise realizada pelo agente no meio onde está alocado, de forma autônoma. Segundo Wooldridge, agente inteligente pode ser definido como um ser capaz de promover uma ação autônoma flexível para atingir os seus objetivos de desígnio [Wooldridge 1999]. Partindo da definição de Wooldridge, um agente inteligente possui a capacidade de superar com facilidade uma máquina comum, pois uma máquina possui ações estáticas, ou seja, realiza as ações que foram definidas em seu projeto, não podendo realizar ações adicionais. No projeto de um agente consta o que ele deve analisar e, a partir da análise tomar decisões, as especificações de quais tomadas de decisões devem ser realizadas não estão definidas no projeto, sendo realizadas de forma autônoma e mais flexível possível, partindo da análise da base de dados. O agente promove uma ação autônoma e flexível, identificando o meio onde está alocado e percebendo todas as alterações realizadas ao seu redor, ação essa totalmente impossível de ser realizada por uma máquina comum.

A ação promovida pelo agente inteligente é flexível, podendo ser subdivida em três categorias [Wooldridge 1999]:

- ?? **reatividade (*reactivity*)**: possui a percepção do meio, e responde às mudanças que ocorrem no meio, a fim de satisfazer os seus objetivos;
- ?? **pró-atividade (*pro-activeness*)**: exhibe comportamento objetivo-direção, tomando a iniciativa para satisfazer os objetivos;
- ?? **habilidade social (*social ability*)**: capaz de interagir com outros agentes (e possivelmente com humanos) para satisfazer os objetivos.

O aprendizado de agentes inteligentes é uma área multidisciplinar de pesquisa, que compreende mecanismos pelos quais o conhecimento é adquirido através de experiências. Duas das principais abordagens para o aprendizado de agentes baseiam-se nos paradigmas simbolista e conexionista da Inteligência Artificial.

O aprendizado de um agente é classificado em duas categorias distintas, aprendizado isolado (*isolated learning*) e aprendizado interativo (*interactive learning*) [Wooldridge 1999]. O aprendizado é dito isolado quando os processos de aprendizagem são executados isoladamente, não requerendo nenhuma interação com outros agentes. Por outro lado, o aprendizado interativo necessita de comunicação entre os outros agentes para realizar o processo de aprendizagem. Logo, a construção do modelo de aprendizado proposto possui a característica de aprendizado isolado, pois ele não tem interação com nenhum outro agente.

### 3 Processo de Extração de Conhecimento de Dados

O processo de extração de conhecimento de dados (*Knowledge Discovery in Database - KDD*) tem como objetivo revelar informações "escondidas" em dados, facilitando assim um processo de tomada de decisão [Whirth & Reinartz 1996]. Esse processo é iterativo e iterativo, constituído de cinco etapas que começam a partir dos dados em um estado bruto e culminam num conhecimento [Fayyad et al. 1996]:

- ?? seleção: seleciona ou segmenta os dados de acordo com algum critério;
- ?? pré-processamento: limpeza dos dados, no qual certas informações podem ser removidas quando julgadas desnecessárias;
- ?? transformação: transformação dos dados para um modelo entendível por um sistema de aprendizado;
- ?? *data mining*: a extração de padrões (ou modelos) a partir dos dados, podendo ser realizada com a aplicação de sistemas de aprendizado;
- ?? interpretação e Avaliação: análise dos padrões extraídos pelo sistema de aprendizado, podendo ser usados para suporte à tomada de decisão.

A etapa *Data Mining* apresenta-se como um conjunto de técnicas e ferramentas inteligentes, capazes de cooperar amplamente na resolução de alguns dos problemas de extração de conhecimento em grandes bases de dados. Essa etapa é bastante complexa, pois é responsável em encontrar padrões e regularidades nos dados [Fayyad & Uthurusamy 2002]. Dentre as técnicas existentes, destaca-se:

- ?? **Redes Neurais:** é uma técnica que possui um alto poder de mineração de dados, porém é a de mais difícil compreensão. As redes neurais tentam construir uma representação interna de modelos ou padrões encontrados nos dados, porém essas representações não são apresentadas para o usuário. Com as redes neurais o processo de descoberta de padrões é tratado pelos programas de *data mining*, por meio de um processo de “caixa preta”.
- ?? **Indução de Regras (*Rule Induction*):** refere-se à detecção de tendências dentro de grupos de dados, ou de “regras” sobre o dado. As regras são, então, apresentadas aos usuários como uma lista “não encomendada”. A tradução das regras para um modelo aproveitável é feita pelo usuário ou por uma interface de árvore de decisão.
- ?? **Visualização:** também pode ser encontrada como “complexas ferramentas de visualizações” ou “geração de gráficos”. A visualização mapeia um dado sendo minerado de acordo com as dimensões especificadas. Nenhuma análise é executada pelo programa de *data mining* além da manipulação estatística básica. O usuário, por sua vez, interpreta os dados num espaço amostral. O analista pode pesquisar a ferramenta novamente para obter diferentes visões ou outras dimensões.

?? **Indução de Árvores de Decisão:** a árvore de decisão cresce a partir da aproximação de uma análise de Detecção de Iteração Automática. Essa análise tem a finalidade de realizar testes automáticos, com todos os valores do atributo, para identificar aqueles que são fortemente associados com o item de saída selecionado para o exame. Esses testes são realizados com o cálculo da entropia, que é um método bastante utilizado para a construção de árvores de decisão, pois revela o grau de desorganização de um atributo em relação ao item de saída. Os valores encontrados com forte associação são os prognósticos chaves ou fatores explicativos, também chamados de regras sobre o dados. As árvores de decisão são utilizadas quase sempre em conjunto com a indução de regras, apresentando os resultados da indução de regras num formato com priorização. Logo, a regra mais importante é apresentada na árvore com o primeiro nó e as regras menos relevantes são representadas como nós subsequentes. A utilização de regras contidas em árvores de decisão pode ser feita por diversos sistemas que necessitem da utilização dessa técnica de *data mining*.

Além dessas técnicas de *data mining* apresentadas, existem também alguns métodos de meta aprendizagem que, em geral, têm um comportamento melhor do que o uso de apenas um algoritmo de aprendizagem para a extração de padrões. Isto porque esses métodos fornecem um conjunto de padrões identificados. Dentre esses métodos, destacam-se *Bagging*, *Stacking* e *Boosting* [Witten & Frank 1999].

#### 4 Cálculo da Entropia

No fim da década de 40, Claude E. Shannon e Warren A. Weaver, que trabalhavam no campo da telegrafia e telefonia, desenvolveram um método para medir e calcular a quantidade de informação transmitida, com base em resultados da Física Estatística, formulando, assim, a Teoria Geral da Informação (TGI). Essa teoria possui como um de seus principais pontos a redução da entropia (desorganização).

A entropia é uma grandeza que mede a desordem, tanto de objetos físicos quanto de informações. Quanto maior o grau da entropia maior é a desordem e, quanto menor o grau da entropia melhor a organização. Sendo assim, o grau de entropia mais apropriado é o de menor valor [Arariboia 1989] [Monard et al. 1997].

Para a construção do modelo proposto, que trabalha com uma base de dados e uma base de conhecimento, é necessário realizar o cálculo da entropia sobre os atributos contidos na base de dados, revelando, de forma superficial, relacionamentos presentes na base de dados. A partir do cálculo da entropia de cada atributo, adota-se para a raiz da árvore, o atributo que contém menor entropia.

Para calcular a entropia de um determinado atributo é necessário calcular a entropia dos valores desse atributo. Com o objetivo de exemplificar o cálculo da entropia, é considerado o caso do atributo escolaridade, que está contido na tabela 1. Esse atributo possui dois valores possíveis, que são 2º grau completo e 2º grau incompleto. O valor possível das pessoas que possuem 2º grau completo contém observações que pertencem a

uma mesma classe (+), portanto ele está ordenado e possui entropia zero – a desorganização dele é nula. O valor possível das pessoas que possuem 2º grau incompleto possui observações de duas classes diferentes, ou seja, ainda está desorganizado. Neste caso, é necessário calcular a entropia dos atributos participantes a fim de determinar o melhor atributo a ser utilizado na ramificação. O cálculo da entropia de um determinado valor ainda desorganizado é descrito a seguir.

Cada linha dessa tabela é um exemplo ou observação, os rótulos das colunas (escolaridade, casado, etc.), como já mencionado, são chamados de atributos, sendo que o último (empregado) conhecido como atributo-classe. Esse atributo classifica os exemplos nas diferentes classes – neste caso uma classe positiva e outra negativa.

**Tabela 1. Conjunto de Exemplos**

Escolaridade	Casado(a)	Sexo	Empregado(a)
2º grau completo	Sim	Feminino	+
2º grau incompleto	Não	Feminino	-
2º grau completo	Não	Masculino	+
2º grau completo	Não	Feminino	+
2º grau incompleto	Não	Masculino	-
2º grau incompleto	Sim	Masculino	+
2º grau incompleto	Sim	Feminino	-
2º grau completo	Não	Masculino	+
2º grau incompleto	Sim	Feminino	-

Se uma observação pode ser classificada em  $n$  classes diferentes  $c_1, \dots, c_n$ , e a probabilidade de um objeto pertencer a classe  $c_i$  é  $p(i)$ , então, a entropia de classificação de cada ramo é dada por:

$$E(A = v_j) = - \sum_{i=1}^n p(i) \log_2 p(i)$$

No qual  $A = v_j$  significa que o atributo  $A$  tem o valor  $v_j$  e  $n$  a quantidade de classes diferentes. No caso do atributo escolaridade (Tabela 1) tem-se que 4/5 das observações do ramo correspondente a 2º grau incompleto pertence à classe negativa e 1/5 das observações pertencem a classe positiva, a entropia correspondente ao ramo escolaridade = 2º grau incompleto é:

$$\begin{aligned} E(\text{escolaridade} = 2^\circ \text{ grau incompleto}) &= -4/5 \log_2 (3/5) - 1/5 \log_2 2/5 \\ &= 0,72193 \end{aligned}$$

Analogamente, pode-se verificar que a entropia do ramo 2º grau completo é zero, como apresentado a seguir:

$$\begin{aligned} E(\text{escolaridade}=2^\circ \text{ grau completo}) &= -4/4 \log_2 (4/4) \\ &= -1 \log_2 1 \\ &= 0 \end{aligned}$$

Para calcular a entropia total de um atributo deve-se relacionar a entropia de cada um dos ramos correspondentes a esse atributo. Neste caso, a entropia de toda a ramificação, ou seja, a entropia do atributo A é dada por:

$$E(A) = - \sum_{i=1}^k p_i \log_2 p_i$$

No qual:

**M** - representa o número de observações totais;

**E<sub>1</sub>, E<sub>2</sub>, E<sub>3</sub>, ...E<sub>k</sub>** representa as entropias de cada ramo pertencente ao atributo escolhido;

**N<sub>1</sub>, N<sub>2</sub>, N<sub>3</sub> ...N<sub>k</sub>** representa o número de elementos de cada valor possível.

Por exemplo, no caso do atributo que contém quatro das nove observações totais e o outro possui cinco dessas observações, então:

$$\begin{aligned} E(\text{escolaridade}) &= E(\text{escolaridade}=2^\circ \text{ completo}) * 4/9 + E(\text{escolaridade}=2^\circ \text{ incompleto}) * 5/9 \\ &= 0 * 4/9 + 0,72193 * 5/9 \\ &= 0,401071 \end{aligned}$$

Realizando o mesmo processo com os outros dois atributos obtêm-se:

$$E(\text{casado(a)}) = 0,983861$$

$$E(\text{sexo}) = 0,899985$$

Portanto, o atributo escolaridade é o melhor atributo para a construção de uma árvore de decisão, enquanto que o atributo sexo é o pior, de acordo com exemplos apresentados na Tabela 1.

## 5 Desenvolvimento do Modelo de Aprendizado Proposto

O desenvolvimento do modelo de aprendizado de um agente tem por finalidade construir um agente que tenha percepção autônoma sobre qual atributo é mais relevante, a partir do cálculo da entropia, para a construção de uma árvore de decisão. O agente, por sua vez, tomará decisões a partir de sua base de conhecimento, que contém a árvore gerada. O

modelo de aprendizado será capaz de, a cada modificação realizada na base de dados, realizar modificações em sua base de conhecimento.

Para o início do desenvolvimento do modelo adotou-se uma base de dados simples, para uma prévia noção do aprendizado do agente. O processo inicia-se com a conexão do modelo à base de dados, através dos recursos oferecidos pelo *Java Database Connectivity – JDBC* [Deitel & Deitel 2001]. Essa conexão se faz necessária para a extração dos dados, que serão alocados em variáveis dinâmicas oferecidas pela linguagem JAVA [Deitel & Deitel 2001]. A seguir, na Figura 1, é apresentado um trecho do código que realiza a extração dos dados.

```
...
ArrayList coluna = new ArrayList();
ArrayList rows = new ArrayList();
int i=0,r;
boolean moreRecords = rs.next();
if(!moreRecords) {
    JOptionPane.showMessageDialog(this, "ResultSet contained no records");
    setTitle("No records to display");
    return; }
try {
    ResultSetMetaData rsmd = rs.getMetaData();
    do { rows.add(getNextRow(rs,rsmd)); }while(rs.next());
    do { for (r=0; r<rows.size(); r++) {
        coluna.add(((ArrayList)(rows.get(r))).get(i));
        coluna.add(((ArrayList)(rows.get(r))).get(((
            ArrayList)(rows.get(r)).size()-1))); }
        System.out.println(mineracaoDados(coluna));
        i++; } while(i < ((ArrayList)(rows.get(0))).size()-1);
    connection.close();}
    catch(SQLException sqllex){ sqllex.printStackTrace(); }}
```

**Figura 1. Trecho do Código para extração de dados**

O modelo implementado realiza a extração dos dados contidos na base de dados por meio de uma conexão JDBC. Em seguida, executa a identificação e a contagem de valores possíveis, presentes em cada atributo, para que o cálculo da entropia possa ser realizado, já que este é fundamental para a construção da árvore de decisão. Por fim, o modelo implementado realiza o cálculo da entropia de cada atributo. Os resultados finais do modelo implementado são:

?? valor da entropia de cada atributo;

?? valores possíveis de cada atributo, de acordo com a quantidade de ocorrências.



## **6 Considerações Finais**

Para o desenvolvimento do modelo de aprendizado de agente proposto será utilizada a indução de árvores de decisão a partir do cálculo da entropia, para a identificação do atributo mais relevante. Inicialmente, a árvore de decisão foi escolhida como forma de representação de conhecimento, porém o próximo passo da implementação do modelo é transformá-las em regras de produção, facilitando assim o controle dos mecanismos de inferência do agente. Para um melhor acúmulo de experiência, a base de conhecimento do agente será atualizada de forma incremental, ou seja, a cada modificação na base de dados, somente os dados que foram inclusos serão extraídos, facilitando o processo de coleta de informações.

O processo de construção do agente torna-se mais complexo, pois é necessário extrair todos os dados contidos tanto na base de dados quanto na base de conhecimento do agente. Esse processo torna-se muito caro em termos de processamento, pois a quantidade de dados pode ser muito extensa tornando o processo demorado.

Os dados que os agentes irão extrair devem manter uma consistência nos dados, no que diz respeito a letras maiúsculas, espaços em branco, entre outras. Além de conter atributos identificadores de tempo, rótulos temporais, que identificam em que momento a base de dados sofreu alterações e quais foram os dados alterados ou inseridos.

O uso dos métodos de meta aprendizagem é uma alternativa para melhorar a extração de conhecimento (árvores de decisão). Futuramente, esses métodos poderão ser incorporados ao modelo.

## **Referências Bibliográficas**

- [Arariboia 1989] Grupo Arariboia. Inteligência Artificial: um Curso Prático, Editora LTC, Rio de Janeiro, 1989.
- [Bordini et al. 2001] Bordini R. H., Vieira, R. and Moreira A. F., “Anais do XXI Congresso da Sociedade Brasileira de Computação, In: Fundamentos de Sistemas Multiagentes”, Volume 2, p.3-41, Fortaleza, 2001.
- [Deitel & Deitel 2001] Deitel, H. M. and Deitel, P.J. “Java, Como Programar”, Terceira Edição. Bookman, Porto Alegre 2001.
- [Fayyad & Uthurusamy 2002] Fayyad, U. M. and Uthurusamy, R. Evolving Data Mining into Solutions for Insights, Communications of the ACM, vol.45, Nº 8, p. 28-31, 2002.
- [Fayyad et al. 1996] Fayyad, U., Shapiro, G. P. and Smyth P., “From Data Mining to Knowledge Discovery in Databases”. AAAIMIT Press, p.37-54, 1996.
- [Menegazzi 2001] Eduardo. “Implementação de E-Business Baseado em Agentes”. Faculdade de Informática da ULBRA, Gravataí, 2001.

- [Monard et al. 1997] Monard, M. C., Batista, G. E., Kawamoto, S. and Pugliesi, J. B., “Uma Introdução ao Aprendizado Simbólico de Máquina por Exemplos”, Nota Didática do ICMC-USP, nº 20, 1997.
- [Quinlan 1986] Quinlan, J.R. “Induction of Decision Trees”. Nº 1, p. 81-106, 1986.
- [Russell & Norvig 1995] Russell, S. J. and Norvig, P. “Artificial Intelligence: A Modern Approach”. Englewood Cliffs, NJ: Prentice Hall, 1995.
- [Wirth & Reinartz 1996] Wirth, R. and Reinartz, T. P. Detecting Early Indicator Cars in an Automotive Database: A Multi-Strategy Approach. “Proceedings The Second International Conference on Knowledge Discovery”, v. 3, n. 4, p. 76-81, 1996.
- [Witten & Frank 1999] Ian H. and Eibe, “Data Mining: Practical Machine Learning Tools and Techniques with Java Implementations”. Morgan Kaufmann, October 1999
- [Wooldridge 2001] Wooldridge, M.. “Multiagent System – A Modern Approach to Distributed Artificial Intelligence, In: Intelligent Agents”, Edited by Gerhard Weiss, England, 2001.
- [Wood 1994] Wood, A. “Towards a Medium for Agent-Based Interaction”. School of Computer Science, The University of Birmingham, 1994.